


Machine Learning Aplicado à Previsão e Agrupamento de Anormalidade da Coluna Vertebral: Uma Análise Comparativa de Random Forest e K- Means

Acadêmicos: Diego, Igor, Davi, João



Introdução

A anormalidade na coluna vertebral representa um desafio significativo na saúde pública global. A aplicação de técnicas de Aprendizagem de Máquina tem se mostrado promissora na identificação de padrões e fatores de risco, auxiliando no diagnóstico precoce.

A presente apresentação visa avaliar o desempenho do algoritmo de classificação Random Forest na previsão do status de anormalidades na coluna vertebral e, em paralelo, explorar se o algoritmo não supervisionado K-Means é capaz de identificar grupos de registros com base em seus perfis de risco. Para isso, foi utilizada uma base de dados abrangente de registros, retirados do site kaggle.




Fundamentação Teórica

Random Forest

É um algoritmo de aprendizado de máquina supervisionado, sendo a combinação de múltiplas árvores de decisão para chegar em um resultado único e preciso. Assim capaz de lidar tanto com problemas de classificação e regressão.

K-Means

É um algoritmo de aprendizado de máquina não supervisionado, sua função principal é agrupar pontos de dados não rotulados em k grupos (clusters) com base na sua similaridade.



Fatores de Anormalidades na Coluna Vertebral

As anormalidades da coluna vertebral são as principais causas de dores crônicas e incapacidade funcional, segundo a OMS sendo predominante nas condições musculoesqueléticas como maior responsável por causar incapacidade no mundo, dividido em várias condições que comprometem a estrutura, alinhamento e função da coluna. Classificados em dois fatores de riscos sendo eles:

1


Fatores de Riscos Não Modificáveis

- Envelhecimento
- Genética
- Doenças ósseas e neuromusculares
- Gênero

2

Fatores de Riscos Modificáveis

- Postura inadequada
- Sedentarismo
- Uso excessivo de dispositivos eletrônicos
- Transporte inadequado de peso
- Carga ocupacional elevada
- Diabetes
- Tabagismo
- Obesidade



Variáveis na Biomecânica da Coluna Lombar e Pelve

O dataset é dividido em 6 variáveis que determinam condições de anormalidades, feitas através de exames radiológicos, sendo elas:

→ Lordose Lombar (LL)

Refere-se à curvatura anterior da coluna lombar, localizada no segmento inferior do tronco.

→ Inclinação Sacral (IS)

É um parâmetro no equilíbrio espinopélvico, indica o ângulo entre o platô superior de S1 e uma linha horizontal.

→ Versão Pélvica (VP)

É um parâmetro que mede o ângulo entre uma linha que liga o ponto médio do platô sacral até o eixo da cabeça femoral, e uma linha vertical perpendicular ao solo.

→ Incidência Pélvica (IP)


É uma técnica definida através da fórmula da soma da inclinação sacral e versão pélvica, definida como ângulo entre uma linha ao ponto médio do platô sacral e a uma linha até o eixo central da cabeça femoral. Sendo assim a fórmula $IP = IS + VP$.

→ Raio Pélvico (RP)

É uma técnica que traça uma linha reta, entre o eixo do quadril e o canto posterior da placa terminal S1, assim o ângulo formado entre a linha RP e a placa terminal sacral, o RP1, sendo a medida do desenvolvimento da morfologia sacropélvica.

→ Grau de Espondilolistese

É o deslizamento vertical da coluna, sendo definido como deslizamento ou escorregamento entre vértebras.



Implementação do Random Forest



Aquisição e Verificação de Dados

O conjunto de dados (Vertebral Column Data Set) foi obtido no repositório Kaggle no formato CSV, contendo 310 registros iniciais. Aplicado verificação de dados repetidos e nulos.



Engenharia de Features

Aplicado a eliminação de excesso de números após a vírgula e a mudança dos dados da variável *Class_att* de Abnormal para Anormal.



Análise Exploratória

Aplicado uma análise exploratória para a identificação de anormalidades de acordo com referências citadas no artigo.



Aplicados o Modelo

Aplicados as configuração, separação das features e target e aplicado a execução do modelo.



Avaliação e Desempenho

Métricas para avaliar a performance e eficácia do modelo ao discriminar os registros anormais e normais.

Código aplicado e armazenado no GITHUB.

Análise Exploratória

O dataset inicialmente foi aplicado uma análise de exploratória para identificação de padrões e grupos, sendo usado métricas de medições através do artigo *"Incidência Pélvica: um parâmetro fundamental para definição do equilíbrio sagital da coluna vertebral e Classificação de Meyerding"*, sendo os resultados gerados.



Visão Geral

Total de registros: 310 registros

 Normais

32.26%

(100 registros)

 Anormais

67.74%

(209 registros)



Crítérios Radiológicos

Critério	Anormais (%)	Normais (%)	Faixa normal
Incidência Pélvica	49.35	50.65	40-65°
Versão Pélvica	40.00	60.00	10-25°
Lordose Lombar	37.10	62.90	40-80°
Inclinação Sacral	45.16	54.84	30-50°



Raio Pélvico

Distribuição	Faixas	Quantidade de Registros	Percentual (%)
Anormal	< 83.7	3	1.29
Indefinido	83.7 - 92.9	7	2.26
Normal	92.9 >	298	96.45



Grau de Espondilolistese

Grau	Registros	Percentual (%)
Grau 0 (normal)	58	18.71
Grau I (1-25%)	116	37.42
Grau II (26-50%)	68	21.94
Grau III (51-75%)	46	14.84
Grau IV (76-100%)	11	3.55
Grau V (>100%)	11	3.55

Preparação dos Dados para o Algoritmo Random Forest

1

Variáveis Selecionados

- pelvic incidence
- pelvic tilt
- lumbar lordosis angle
- sacral slope
- pelvic radius
- grade of spondylolisthesis

2

Formato dos Dados

- features: 310 registros
- target: 310 registros

3

Divisão dos Dados

- Treino: 217 registros (70%)
- Teste: 93 registros (30%)

4

Distribuição das Classes

- Dataset completo: 67.74% possuem anormalidades
- Conjunto de TREINO: 67.74% possuem anormalidades
- Conjunto de TESTE: 67.74% possuem anormalidades

5

Hiperparâmetros Configurados

- Árvores: 100
- Profundidade máxima: 10
- Amostras mínimas para dividir: 5
- Estratégia de features: sqrt

Avaliação do Modelo Treinado Random Forest

Informações do Modelo

- Número de árvores criadas: 100
- Classes aprendidas: Anormal e Normal
- Profundidade média das árvores: 8.5

Acurácia

0.8172 (81.72%)

Percentual total de previsões corretas

AUC-ROC



0.933

Capacidade de distinguir entre anormal e normal

Relatório Detalhado de Classificação

	precision	recall	f1-score	support
Anormal	0.897	0.825	0.860	63
Normal	0.686	0.800	0.738	30
accuracy		0.817		93
macro avg	0.791	0.813	0.799	93
weighted avg	0.829	0.817	0.820	93

Matriz de Confusão e Curva Roc



Verdadeiros Negativos

52

Normais classificados como **Normais**

Verdadeiros Positivos

24

Anormais classificados como **Anormais**

Falsos Positivos

11


Normais classificados como **Anormais**

Falsos Negativos

6

Anormais classificados **Normais**

Importância das Variáveis no Modelo Random Forest




Variável mais importante

grade of spondylolisthesis - 38,01%

Variável menos importante

sacral slope - 8,75%

Implementação do Modelo K-Means




Implementado o código para encontrar o K ideal para gerar os agrupamentos, através do método do cotovelo, gerou-se um gráfico para melhor visualização. Assim sendo selecionado $K = 2$.

Gráfico de Identificação de Perfil Médio

Depois de selecionado o K ideal foi implementado o código do agrupamento dos dados, como resultado se gerando um gráfico para determinar o perfil médio das características por clusters, assim determinado pelo K ideal 2.

Perfil Médio das Características por Cluster (K=2)



Avaliação Externa

Finalizando com a avaliação para determinar a eficácia do modelo, através de métricas de concordância, sendo o resultado:

Adjusted Rand Index (ARI)

0.0995

Similiaridade entre os agrupamentos

Normalized Mutual Information (NMI)

0.1600

A quantidade de informação compartilhada entre os agrupamentos

Matriz de Contingência (Real vs Cluster)

Cluster	0	1
Real		
Anormal	66	81
Normal	63	7

Conclusão

Este estudo avaliou a aplicação dos algoritmos Random Forest e K-Means para previsão e agrupamento de um dataset de registros referente à coluna vertebral. O modelo Random Forest alcançou uma acurácia geral de 81,72%, mas apresentou na precisão de classificar o Normal um valor mais baixo de 0,686, assim gerando falsos positivos, mais com um Recall de 0.825 para anormal e 0,800 para normal, o modelo apresenta uma sensibilidade satisfatória, provavelmente, pelo desbalanceamento do dataset 209 anormais e 100 normais.

A análise de importância das variáveis forneceu um insight clínico crucial, destacando o Grau de Espondilolistese como o fator mais preditivo. Por outro lado, o K-Means demonstrou ser ineficaz neste contexto, mesmo aumentando o número de clusters, não conseguindo gerar correlação com a situação clínica real dos registros.

Como trabalho futuro, é essencial a aplicação de técnicas de balanceamento de classes no dataset para mitigar o viés do modelo Random Forest em favor da classe minoritárias, visando uma melhora na precisão.



Referência

- FLORES, Fernando. **Conheça os tipos e fatores de risco das alterações posturais**. 21 jul. 2025. Disponível em: <https://www.drfernandoflores.com.br/tipos-e-fatores-de-riscos-das-alteracoes-posturais>. Acesso em: 6 jun. 2026.
- EKŞİ, M. Şakir et al. **Is diabetes mellitus a risk factor for modic changes?: A novel model to understand the association between intervertebral disc degeneration and end-plate changes**. *Journal of Orthopaedic Science*, v. 25, n. 4, p. 571-575, jul. 2020. DOI 10.1016/j.jos.2019.09.005. Disponível em: <https://pubmed.ncbi.nlm.nih.gov/31564384/>. Acesso em: 6 jun. 2026.
- RAHME, R.; MOUSSA, R. **Modic changes: their pathophysiological and clinical significance**. *Neurochirurgie*, v. 54, n. 1, p. 1-8, fev. 2008. DOI 10.1016/j.neuchi.2007.10.002. Disponível em: <https://pubmed.ncbi.nlm.nih.gov/18194532/>. Acesso em: 6 jun. 2026.
- MELEPURA, Febin. **What causes lower back pain in females? A NYC pain specialist explains**. *SPIN NYC Blog, New York*, 3 jun. 2026. Disponível em: <https://www.sportspainmanagementnyc.com/blog/what-are-common-causes-of-lower-back-pain-in-women>. Acesso em: 6 jun. 2026.
- TEIXEIRA, Ricardo. **Lordose lombar: o que realmente importa? Dr. Ricardo Teixeira - Ortopedia e Cirurgia da Coluna, São Paulo, 2 ago. 2024**. Disponível em: <https://drricardoteixeira.com.br/lordose-lombar/>. Acesso em: 6 jun. 2026.
- RADIOLOGIA ONLINE. **Medidas ortopédicas**. [S.l.], 26 dez. 2017. Disponível em: <https://radiologia.online/medidas-ortopedicas/>. Acesso em: 6 jun. 2026.
- SERGIDES, I. G. et al. **Lumbo-pelvic lordosis and the pelvic radius technique in the assessment of spinal sagittal balance: strengths and caveats**. *European Spine Journal*, [s.l.], v. 20, n. Suppl 5, p. 591-601, 24 ago. 2011. DOI 10.1007/s00586-011-1926-z. Disponível em: <https://pmc.ncbi.nlm.nih.gov/articles/PMC3175929/>. Acesso em: 6 jun. 2026.
- RODRIGUES, Thiago. **Espondilolistese: tudo o que você precisa saber!**. *Neurocirurgia | Dr. Thiago Rodrigues MD, PhD, 2022*. Disponível em: <https://neurocirurgiasp.com.br/artigos/servico-de-neurocirurgia/o-que-e-espondilolistese/>. Acesso em: 6 jun. 2026.
- JSR90. **Vertebral Column Data Set**. Kaggle, 21 jul. 2022. Disponível em: <https://www.kaggle.com/datasets/jessanrod3/vertebralcolumndataset/data>. Acesso em: 1 jun 2026.



Duvídas?